



UNIVERSITA' DEGLI STUDI DI CAGLIARI

FACOLTÀ DI SCIENZE

Corso di Laurea Magistrale in Informatica

Data Mining: Report Finale

Gruppo G3.3

Componenti:

Aresu Matteo

60/99/00014

Mantega Gabriele

60/99/00006

Masala Gabriele

60/99/00004

ANNO ACCADEMICO 2025-2026

Indice

1	Introduzione	3
2	Dataset	4
3	Preprocessing	5
4	Applicazione Modelli	5
5	Discussione	5
6	Conclusioni	5

1 Introduzione

Il seguente report affronta il problema della classificazione dei documenti testuali, nel campo dell'analisi delle informazioni reperite da dei forum online, con lo scopo di dibattere e discutere su topic ben determinati. I forum in questione sono chiamati **newsgroup**, degli spazi virtuali creati su una rete di calcolatori distribuita e interconnessa su un sistema decentralizzato. L'obiettivo che ci è stato posto per il progetto è quello di utilizzare diversi modelli di classificatori, sia shallow che ensemble, per valutarne le prestazioni su un task di classificazione dei topic, a partire da un post dato in input. La valutazione delle prestazioni si è basata non solo su i modelli di classificazione, ma anche sui metodi di rappresentazione geometrica dei dati in input. A questo scopo sono stati utilizzati due metodi di vettorizzazione: **TF-IDF** e **GloVe**.

Nel secondo capitolo viene affrontata un'analisi approfondita del dataset **20newsgroups**, un'insieme di documenti testuali ampiamente utilizzati nel campo del Natural Language Processing, con approfondimento su alcune categorie scelte. Nel terzo capitolo viene descritto il flusso di elaborazione e trasformazione dei dati, differente per i due metodi di vettorizzazione scelti, con relativo approfondimento sulle scelte prese durante lo sviluppo. Nel quarto capitolo vengono elencati i classificatori di machine learning utilizzati, i relativi risultati di training e testing sul dataset e scelte implementative effettuate sugli iperparametri. Nel quinto capitolo vengono discussi esaurientemente i risultati ottenuti, con considerazioni argomentate, e rappresentazione visiva dei dati.

2 Dataset

Il dataset preso in esame è **20newsgroups**. Al suo interno riporta quasi 20.000 pubblicazioni (post) suddivise per categorie tematiche, per un totale di venti topic, distribuiti in macro-categorie e delle sotto-categorie. Queste vengono esplicitate tramite una gerarchia, con la seguente struttura: `macrocategoria.sottocategorie`. Il dataset è un insieme di documenti puramente testuali, ed è adatto per la valutazione delle prestazioni dei modelli di classificazione. La documentazione relativa è possibile consultarla al seguente link:
<https://www.kaggle.com/datasets/crawford/20-newsgroups>.

From: baalke@kelvin.jpl.nasa.gov (Ron Baalke)
Subject: Galileo Update - 04/15/93
Organization: Jet Propulsion Laboratory
Lines: 113
Distribution: world
NNTP-Posting-Host: kelvin.jpl.nasa.gov
Keywords: Galileo, JPL
News-Software: VAX/VMS VNEWS 1.41

Forwarded from Neal Ausman, Galileo Mission Director

GALILEO
MISSION DIRECTOR STATUS REPORT
POST-LAUNCH
April 9 - 15, 1993

SPACECRAFT

1. On April 9, real-time commands were sent, as planned, to reacquire celestial reference after completion of the Low Gain Antenna (LGA-2) swing/Dual Drive Actuator (DDA) hammer activities.

...

Figura 1: Estratto di un post del topic `sci.space`

Delle categorie presenti nel dataset sono state analizzate soltanto cinque per le elaborazioni richieste: `rec.autos`, `rec.sport.baseball`, `sci.electronics`, `sci.med` e `sci.space`.

Ogni elemento del dataset rappresenta un singolo post, con vari utenti che mandano messaggi e discutono sul topic in esame. Ogni messaggio è a sua volta suddiviso tra header e contenuto. In Figura 1 è possibile vedere l'inizio di un messaggio presente nel dataset.

- 3 Preprocessing**
- 4 Applicazione Modelli**
- 5 Discussione**
- 6 Conclusioni**