



UNIVERSITA' DEGLI STUDI DI CAGLIARI

FACOLTÀ DI SCIENZE

Corso di Laurea Magistrale in Informatica

Data Mining: Report Finale

Gruppo G3.3

Componenti:

Aresu Matteo

60/99/00014

Mantega Gabriele

60/99/00006

Masala Gabriele

60/99/00004

ANNO ACCADEMICO 2025-2026

Indice

1	Introduzione	3
2	Dataset	4
3	Preprocessing	5
4	Applicazione Modelli	5
5	Discussione	5
6	Conclusioni	5

1 Introduzione

Questo report affronta il problema della classificazione dei documenti testuali, applicato all'analisi delle interazioni interne dei newsgroup, spazi online storicamente strutturati su infrastrutture decentralizzate, e dedicati al dibattito su topic ben determinati. L'obiettivo centrale del progetto è l'utilizzo di diversi algoritmi di classificazione, spaziando dai modelli storici tradizionali (shallow learning) ai modelli a combinazione (ensemble learning), al fine di predire il topic di un post partendo dal contenuto dei suoi messaggi. Lo studio non si è limitato all'analisi delle prestazioni dei classificatori, ma si estende ai metodi di rappresentazione geometrica dei dati in input. a questo scopo sono stati utilizzati due metodi di vettorizzazione: **TF-IDF** (Term Frequency-Inverse Document Frequency) e **GloVe** (Global Vectors for Word Representation).

Il presente report è organizzato nei seguenti passi:

- **Capitolo 2 - Dataset** Analisi approfondita del dataset 20newsgroups, della sua struttura e delle sue categorie tematiche con approfondimento su quelle scelte.
- **Capitolo 3 - Preprocessing** Descrizione del flusso di elaborazione e trasformazione dei dati, differenziando i due metodi di vettorizzazione scelti, con relativo approfondimento sulle scelte di implementazione prese durante lo sviluppo del progetto.
- **Capitolo 4 - Applicazione modelli** Elenco dei classificatori di utilizzati, con i relativi risultati di training e testing sul dataset e scelte implementative effettuate sugli iperparametri.
- **Capitolo 5 - Discussione** Argomentazione esaustiva sui risultati ottenuti con considerazioni argomentate e rappresentazione visiva dei dati, mediante tabelle e grafici informativi.

2 Dataset

Il dataset preso in esame è **20newsgroups**. Al suo interno riporta quasi 20.000 pubblicazioni (post) suddivise per categorie tematiche, per un totale di venti topic, distribuiti in macro-categorie e delle sotto-categorie. Queste vengono esplicitate tramite una gerarchia, con la seguente struttura: `macrocategoria.sottocategorie`. Il dataset è un insieme di documenti puramente testuali, ed è adatto per la valutazione delle prestazioni dei modelli di classificazione. La documentazione relativa è possibile consultarla al seguente link:
<https://www.kaggle.com/datasets/crawford/20-newsgroups>.

```
From: baalke@kelvin.jpl.nasa.gov (Ron Baalke)
Subject: Galileo Update - 04/15/93
Organization: Jet Propulsion Laboratory
Lines: 113
Distribution: world
NNTP-Posting-Host: kelvin.jpl.nasa.gov
Keywords: Galileo, JPL
News-Software: VAX/VMS VNEWS 1.41
```

Forwarded from Neal Ausman, Galileo Mission Director

GALILEO
MISSION DIRECTOR STATUS REPORT
POST-LAUNCH
April 9 - 15, 1993

SPACECRAFT

1. On April 9, real-time commands were sent, as planned, to reacquire celestial reference after completion of the Low Gain Antenna (LGA-2) swing/Dual Drive Actuator (DDA) hammer activities.

...

Figura 1: Estratto di un post del topic `sci.space`

Delle categorie presenti nel dataset sono state analizzate soltanto cinque per le elaborazioni richieste: `rec.autos`, `rec.sport.baseball`, `sci.electronics`, `sci.med` e `sci.space`.

Ogni elemento del dataset rappresenta un singolo post, con vari utenti che mandano messaggi e discutono sul topic in esame. Ogni messaggio è a sua volta suddiviso tra header e contenuto. In Figura 1 è possibile vedere l'inizio di un messaggio presente nel dataset.

- 3 Preprocessing**
- 4 Applicazione Modelli**
- 5 Discussione**
- 6 Conclusioni**