



UNIVERSITA' DEGLI STUDI DI CAGLIARI

FACOLTÀ DI SCIENZE

Corso di Laurea Magistrale in Informatica

Data Mining: Report Finale

Gruppo G3.3

Componenti:

Aresu Matteo

Mantega Gabriele

Masala Gabriele

60/99/00014

60/99/00006

60/99/00004

ANNO ACCADEMICO 2025-2026

Indice

1	Introduzione	3
2	Dataset	4
3	Preprocessing	4
4	Applicazione Modelli	4
5	Discussione	4
6	Conclusioni	4

1 Introduzione

Il seguente report affronta il problema della classificazione dei documenti testuali, nel campo dell'analisi delle informazioni reperite da dei forum online, con lo scopo di dibattere e discutere su topic ben determinati. I forum in questione sono chiamati **newsgroup**, degli spazi virtuali creati su una rete di calcolatori distribuita e interconnessa su un sistema decentralizzato. L'obiettivo che ci è stato posto per il progetto è quello di utilizzare diversi modelli di classificatori, sia shallow che ensemble, per valutarne le prestazioni su un task di classificazione dei topic, a partire da un post dato in input. La valutazione delle prestazioni si è basata non solo su i modelli di classificazione, ma anche sui metodi di rappresentazione geometrica dei dati in input. A questo scopo sono stati utilizzati due metodi di vettorizzazione: **TF-IDF** e **GloVe**.

- 2 Dataset**
- 3 Preprocessing**
- 4 Applicazione Modelli**
- 5 Discussione**
- 6 Conclusioni**